

Desempenho e Dimensionamento de Redes e Sistemas

Laboratório n.º 1 – Simulação de eventos discretos

Trabalho realizado por:

Diogo Fonseca -121597,
João Simões - 107246,
Tiago Oliveira - 123275

Grupo 4

Nota: O código R desenvolvido em cada exercício encontra-se disponível no repositório Git <https://github.com/JoaoASimoes/DDRS-Labs> (branch *main*), organizado por exercício.

Exercício 1

Foram gerados 1000 números pseudoaleatórios com distribuição uniforme no intervalo $[0, 1]$, utilizando a função `runif()`, e representados através de um histograma.

Distribuição de 1000 números aleatórios uniformes




Figura 1 - Histograma de 1000 números aleatórios uniformemente distribuídos em $[0, 1]$.

Como esperado para uma distribuição uniforme, as frequências apresentam-se aproximadamente constantes ao longo do intervalo. As diferenças observadas entre as barras resultam da aleatoriedade da amostra e não indicam, por si só, um desvio à distribuição uniforme.

Exercicio 2

Um TRGN(True Random Number Generator) é baseado em fenômenos físicos imprevisíveis e não determinísticos para produzir números realmente aleatórios. Em contrapartida, um PGRN(Pseudo Random Number Generator) utiliza algoritmos matemáticos determinísticos baseados numa fórmula do tipo $Z_i = aZ_{i-1} + c \pmod{m}$. Posteriormente os números obtidos são normalizados dividindo o valor obtido pelo módulo de m , resultando um valor entre $[0,1]$. Portanto, qualquer valor da sequência pode ser calculado *a priori* a partir dos parâmetros do gerador, ou seja, o processo é estritamente determinístico.

Para demonstrar isto em programação devemos ter em atenção ao conceito de *seed* (Z_0) que é o valor inicial que alimenta a fórmula recursiva do PGRN. Como cada termo Z_i é calculado unicamente em função do termo anterior Z_{i-1} , fixar Z_0 coloca o algoritmo exatamente no mesmo estado inicial, garantindo que toda a sequência de números pseudo-aleatórios gerados subsequentemente seja 100% reproduzível:




Figura 2- Output do código

Como se pode observar na Figura 2., os dois histogramas resultantes são rigorosamente idênticos em todas as suas barras e frequências, confirmando visualmente que a reinicialização da semente ($Z_0 = 123$) força o algoritmo a produzir exatamente a mesma sequência de valores.

Exercício 3

Método

Para gerar uma variável aleatória de Bernoulli com probabilidade de sucesso p , gerou-se um número U uniformemente distribuído em $[0, 1]$ e atribuiu-se o valor 1 (sucesso) quando $U < p$ e o valor 0 (insucesso) caso contrário. Como U é uniforme, $P(U < p) = p$, pelo que o sucesso ocorre com a probabilidade pretendida. Geraram-se 1000 números para cada um de três valores de p (0,2, 0,5 e 0,8), com a semente 123, de forma a garantir a reprodutibilidade dos resultados.

Resultados e discussão

A Figura X-1 apresenta os histogramas obtidos. Em todos os casos, a variável toma apenas os valores 0 e 1, como esperado numa distribuição de Bernoulli. O número de sucessos observado é de aproximadamente 200, 500 e 800 para $p = 0,2$, 0,5 e 0,8, respetivamente, ou seja, a proporção de sucessos aproxima-se de p em todos os casos.

Os pequenos desvios face aos valores esperados (por exemplo, cerca de 507 sucessos em vez de 500 para $p = 0,5$) são compatíveis com a variabilidade aleatória de uma amostra de 1000 números. A frequência relativa de sucessos, $Z(E)$, tem variância dada por (1), com $P(E) = p$ e $N = 1000$, o que, para $p = 0,5$, corresponde a um desvio padrão de cerca de 0,016, ou seja, cerca de 16 sucessos. Conclui-se, de forma informal, que o gerador produz números com a distribuição de Bernoulli pretendida.

$$\text{Var}(Z(E)) = \frac{P(E)(1 - P(E))}{N} \quad (1)$$




Figura 3: Histogramas de 1000 números gerados com distribuição de Bernoulli para (a) $p = 0,2$, (b) $p = 0,5$ e (c) $p = 0,8$.

Exercício 4

Para gerar números com distribuição Exponencial a partir de uma distribuição Uniforme gerada pela função `runif()` (que atua como um PRNG), é necessário recorrer ao Método da Transformação Inversa (*Inverse Transformation Method*).

Este método estabelece que, ao gerar um número aleatório $U \sim Unif(0, 1)$, a aplicação do valor U na função inversa da Função de Distribuição Acumulada, $F^{-1}(U)$, resulta numa variável aleatória X cujo comportamento probabilístico é regido por $F(x) = P(X \leq x)$.

Invertendo a CDF da distribuição Exponencial, $F(x) = 1 - e^{-\lambda x}$, obtemos a expressão analítica de geração: $X = -\frac{1}{\lambda} \ln(U)$. A fórmula deduzida traduz-se diretamente em R. Geram-se $N = 10.000$ variáveis uniformes com a função `runif()`, aplica-se a transformação inversa para calcular o vetor x , e constrói-se o histograma de densidade (`prob = TRUE`) para comparar a amostragem empírica com a Função de Densidade de Probabilidade (PDF) teórica calculada por `dexp()`:




Figura 4- Output

Exercicio 5

A modelação de um Processo de Poisson baseia-se no facto de os tempos entre chegadas consecutivas seguirem uma distribuição Exponencial de taxa λ .

Através da função `rexp()`, geram-se $N=10k$ intervalos de tempo independentes entre eventos sucessivos. Para tornar esses valores em valores contínuos/temporais fizemos uma conversão com a função `cumsum()`, que calcula valores absolutos de cada chegada. A validação deste gerador é feita calculando a taxa amostral, dividindo o número total de eventos pelo tempo acumulado do último evento (N/T_N).

Para uma taxa teórica $\lambda = 3$, o output simulado produz uma taxa amostral de aproximadamente 3.00, o que demonstra uma boa precisão experimental. Esta precisão vai de encontro ao fundamento da Lei Forte dos Grandes Números, que defende que a média dos intervalos entre chegadas tende para $1/\lambda$ quando $N \rightarrow \infty$. Em amostras pequenas (como $N = 10$), a estimativa apresenta elevada variabilidade, enquanto para $N = 10K$ a variância do estimador reduz-se drasticamente, como podemos observar abaixo:

	$N = 10K$	$N = 10$
λ (Taxa amostral)	2.965	2.43
	3.023	2.84
	3.043	4.19

Tabela 1 - λ Taxa amostral em função de intervalos de tempo

Exercicio 6

O modelo estocástico M/M/1 é caracterizado por um processo de chegadas de Poisson de taxa λ e tempos de serviço com distribuição Exponencial de taxa μ , processados por um único servidor operando sob a disciplina FIFO, numa fila de capacidade ilimitada. A viabilidade operacional e a convergência para o regime estacionário dependem estritamente da condição de estabilidade, onde a taxa de utilização do servidor ($\rho = \lambda/\mu$) deve ser inferior a 1. Na perspetiva da simulação computacional, o rastreamento temporal de variáveis de estado - como a ocupação do servidor e a dimensão da fila - permite quantificar o desempenho do sistema.

Para testar empiricamente a teoria descrita, utilizamos o código do Anexo A onde o *algoritmo monitoriza o avanço do relógio de simulação e atualiza continuamente o estado das variáveis - nomeadamente a ocupação do servidor (ServerStatus), o tamanho da fila (NumInQueue) e os instantes de chegada dos clientes (SystemArrivalTime)*. A simulação foi executada para um universo de $N = 10.000$ clientes processados sob dois cenários de carga distintos: um regime de carga leve ($\rho = 0.30$, com $\lambda = 3$ e $\mu = 10$) e um regime de carga elevada ($\rho = 0.80$, com $\lambda = 8$ e $\mu = 10$). Os resultados obtidos são confrontados com os valores teóricos de regime permanente na Tabela 2.

	Variável de Estado	Valor Teórico	Valor Simulado	Erro Relativo (%)
Carga Leve ($\lambda = 3, \mu = 10,$ $\rho = 0.30$)	Utilização (ρ)	0.3	0.3	0
	Atraso na Fila (W_q)	0.0428	0.0411	-3.97
	Atraso no Sistema (W)	0.1428	0.1409	-1.33
Carga Elevada ($\lambda = 8, \mu = 10,$ $\rho = 0.80$)	Utilização (ρ)	0.8	0.8	0
	Atraso na Fila (W_q)	0.4	0.4859	21.48
	Atraso no Sistema (W)	0.5	0.5870	17.4

Tabela 2- Avaliação do simulador M/M/1: Resultados analíticos vs. experimentais em carga leve e elevada.

Os resultados validam a correção do algoritmo, notando uma elevada precisão no cenário de carga leve ($\rho = 0.30$), onde os erros relativos se mantêm inferiores a 4%. Em contrapartida, o desvio acentuado de aproximadamente 21.5% observado na carga elevada ($\rho = 0.80$) reflete claramente o comportamento não-linear dos sistemas M/M/1. Esta discrepância ilustra o impacto da elevada variância estocástica perto do limite de saturação.

Exercício 7

Método

Partiu-se do simulador M/M/1 do Anexo A do guia e acrescentou-se um segundo servidor. A lista de eventos passou a conter três entradas: a próxima chegada e a próxima partida de cada servidor, com valor infinito quando o servidor está livre. Numa chegada, se existir um servidor livre, o cliente inicia o serviço de imediato, com atraso nulo; caso contrário, entra na fila. Numa partida, se a fila não estiver vazia, o primeiro cliente da fila inicia o serviço no servidor que ficou livre e o seu atraso é contabilizado. A simulação termina quando são determinados os atrasos de 100.000 clientes. Testaram-se dois cenários com $\mu = 10$: $\lambda = 8$ ($\rho = 0,4$) e $\lambda = 18$ ($\rho = 0,9$), sendo $\rho = \lambda/2\mu$. Os valores teóricos foram calculados com as expressões do Anexo C do guia. A comparação com os valores teóricos foi feita através do erro relativo γ , definido em (2), em que $\bar{X}$ é o valor simulado e μ o valor teórico de W_Q (e não a taxa de serviço); nas tabelas, o erro relativo é apresentado com sinal, que indica se o valor simulado está acima (+) ou abaixo (-) do teórico.

$$\frac{|\bar{X} - \mu|}{|\mu|} = \gamma_{(2)}$$

Resultados e discussão

λ	μ	ρ	W_Q simulado	W_Q teórico	Erro relativo
8	10	0,4	0,0182	0,0190	-4,2%
18	10	0,9	0,3999	0,4263	-6.2%

Tabela 3: Atraso médio em fila do sistema M/M/2, simulado e teórico (em unidades de tempo).

Os valores simulados aproximam-se dos teóricos nos dois cenários, com erros relativos de $-4,3\%$ e $-6,2\%$, o que valida o simulador. O aumento de ρ de 0,4 para 0,9 (2,25 vezes) faz o atraso médio em fila crescer cerca de 22 vezes, o que evidencia o crescimento não linear do atraso à medida que a carga se aproxima da capacidade do sistema. Para $\rho = 0,9$, a probabilidade de uma chegada encontrar os dois servidores ocupados é de cerca de 85%, contra 23% para $\rho = 0,4$.

Em ambos os cenários o valor simulado fica abaixo do teórico, e o erro relativo é maior para $\rho = 0,9$. Isto é consistente com a maior variabilidade dos atrasos com carga elevada (ver Exercício 12), embora uma única execução por cenário não permita uma conclusão definitiva.

Exercicio 8

Foram simulados 1000 lançamentos de conjuntos de cinco moedas enviesadas, considerando uma probabilidade de cara de $p = 0,7$. A probabilidade de obter exatamente duas caras foi estimada pela frequência relativa deste acontecimento nas simulações.

O valor exato pode ser obtido através da distribuição binomial:

$$P(X = 2) = \binom{5}{2} (0,7)^2 (0,3)^3 = 0,1323.$$

Probabilidade de obter exatamente duas caras




Figura 5 - Comparação entre a probabilidade estimada por simulação e o valor exato.

A estimativa obtida por simulação deverá apresentar um valor próximo de 0,1323, podendo existir uma pequena diferença devido à natureza aleatória da experiência. Como referido nos slides, a frequência relativa constitui um estimador da probabilidade do evento e a sua variabilidade diminui à medida que aumenta o número de experiências realizadas.

Exercicio 9

Para analisar a distribuição do tamanho dos pacotes de dados numa interface de rede, capturou-se o tráfego em tempo real durante um intervalo de 120 segundos com o Wireshark. Em seguida, os dados brutos de cada cenário foram exportados para ficheiros no formato .csv, permitindo a sua importação e tratamento estruturado no ambiente R. A partir daqui, aplicaram-se técnicas de filtragem e visualização para comparar os três perfis de tráfego. No R, isolou-se a variável referente ao tamanho dos pacotes em bytes e aplicou-se um filtro para remover registos superiores a 1514 bytes, eliminando artefactos de medição associados ao *TCP Segmentation Offload* (TSO) e garantindo a integridade dos dados reais de rede. Esta limpeza preveniu distorções nas amostras antes da geração dos resultados gráficos.

Por fim, o script configura um dispositivo gráfico para exportar uma imagem conjunta contendo três histogramas empilhados, padronizando a largura das barras em intervalos fixos e 50 bytes e a mesma escala no eixo horizontal:




Figura 6 - Histogramas da distribuição do tamanho de pacotes em diferentes perfis de utilização da rede.

A análise aos três cenários demonstra como cada aplicação dita a forma do tráfego na nossa rede. No *streaming* do YouTube, assistimos a uma distribuição claramente bimodal, destacando-se um pico massivo de pacotes grandes (1200–1300 Bytes) para garantir fluidez no vídeo, acompanhado de um pequeno pico de pacotes de controlo. Já no download de ficheiros, a rede assume uma distribuição bimodal mais acentuada (em forma de "U"), saturando a ligação com pacotes pesados de 1500 Bytes num dos lados e recebendo uma "chuva" de pequenas confirmações no extremo oposto.

Quando a máquina ficou em idle, o gráfico assumiu uma distribuição fortemente assimétrica positiva, concentrando-se quase exclusivamente em pacotes minúsculos que representam o ruído de fundo do sistema operativo.

Para além das formas dos gráficos, é notório a diferença de volume: o vídeo gerou barras a ultrapassar os 120.000 pacotes, enquanto o modo *idle* mal chegou às 300 unidades.

Exercício 10

Método

Mediram-se 10 RTTs com o comando ping para o servidor `nz.pool.ntp.org`, localizado na Nova Zelândia. A partir das medições, calcularam-se a média e o desvio padrão amostrais e determinaram-se dois intervalos de confiança a 95% para o RTT médio: um baseado na distribuição Normal, (3), com $z_{0,975} = 1,960$, e outro na distribuição t-Student, (4), com $n - 1 = 9$ graus de liberdade e $t_{9;0,975} = 2,262$.

$$\bar{X}(n) \pm z_{1-\alpha/2} \sqrt{S^2(n)/n} \quad (3)$$

$$\bar{X}(n) \pm t_{n-1,1-\alpha/2} \sqrt{S^2(n)/n} \quad (4)$$

Resultados e discussão

Distribuição	Valor Crítico	IC 95% (ms)	Amplitude (ms)
Normal	1,960	[327,73; 329,07]	1,33
t-Student	2,262	[327,63; 329,17]	1,54

Tabela 4: Intervalos de confiança a 95% para o RTT médio ($\bar{X}(n) = 328,4$ ms; $S(n) = 1,07$ ms; $n = 10$).

Os dois intervalos estão centrados na média amostral, mas o da t-Student é cerca de 15% mais largo, devido ao maior valor crítico. Prefere-se o intervalo baseado na t-Student: o desvio padrão da população é desconhecido e foi estimado a partir de apenas 10 observações, e a distribuição t incorpora a incerteza adicional dessa estimação. O intervalo Normal só seria adequado com variância conhecida ou com uma amostra grande, caso em que as duas distribuições praticamente coincidem. Com $n = 10$, o intervalo Normal subestima a incerteza: mesmo que os RTTs fossem normais, a sua cobertura real seria de cerca de 92%, abaixo dos 95% pretendidos.

O intervalo da t-Student pressupõe, ainda assim, que os RTTs seguem uma distribuição normal. Os atrasos de rede tendem a ser assimétricos, uma vez que episódios de congestionamento só podem aumentar o RTT, pelo que, com uma amostra tão pequena, a cobertura real do intervalo pode afastar-se dos 95% (ver Exercício 11).

Exercício 11

Método

Para avaliar a fiabilidade do intervalo de confiança a 95% para a média, consideraram-se quatro distribuições: Normal padrão ($\mu = 0$, $\sigma^2 = 1$), Exponencial com $\lambda = 1$, Lognormal com $\mu = 0$ e $\sigma^2 = 1$ e Lognormal com $\mu = 0$ e $\sigma^2 = 2$. Para cada distribuição e para cada tamanho de amostra $n \in \{5, 10, 50, 5000\}$, realizaram-se 1000 experiências. Em cada experiência, gerou-se uma amostra de tamanho n , construiu-se o IC a 95% baseado na t-Student e verificou-se se este continha a média verdadeira da distribuição (0, 1, $e^{0.5} \approx 1,65$ e $e^1 \approx 2,72$, respetivamente). A cobertura foi estimada por (5), como a proporção de intervalos que contêm a média verdadeira. Sendo uma frequência relativa, a sua variância é dada por (1), com $P(E) = 0,95$ e $N = 1000$, o que corresponde a um erro padrão de cerca de 0,007, pelo que desvios até cerca de 0,014 em relação a 0,95 não são significativos.

$$\hat{C} = (\text{número de ICs que contêm } \mu) / E(5)$$

Resultados e discussão

Distribuição	n = 5	n = 10	n = 50	n = 5000
Normal	0,951	0,957	0,963	0,948
Exponencial ($\lambda = 1$)	0,879	0,895	0,939	0,951
Lognormal (0, 1)	0,825	0,867	0,906	0,959
Lognormal (0, 2)	0,685	0,738	0,850	0,951

Tabela 5: Cobertura estimada do IC a 95% para a média, em função da distribuição e do tamanho da amostra. A negrito, valores significativamente inferiores a 0,95.

Na distribuição Normal, a cobertura mantém-se próxima de 0,95 para todos os tamanhos de amostra, com desvios dentro do erro da estimativa. Isto era esperado, uma vez que o intervalo baseado na t-Student é exato quando os dados são normais, independentemente de n .

Nas restantes distribuições, a cobertura é inferior a 0,95 para amostras pequenas e aproxima-se do valor nominal à medida que n aumenta. A degradação acompanha a assimetria da distribuição: a Exponencial (coeficiente de assimetria 2) atinge uma cobertura aceitável a partir de $n = 50$, a Lognormal com $\sigma^2 = 1$ (assimetria 6,2) só para $n = 5000$, e a Lognormal com $\sigma^2 = 2$ (assimetria 23,7) apresenta a pior cobertura, de apenas 0,685 para $n = 5$ e ainda 0,850 para $n = 50$. Em distribuições assimétricas, as amostras pequenas raramente incluem os valores elevados da cauda, pelo que tendem a subestimar tanto a média como a variância, produzindo intervalos demasiado estreitos e deslocados para baixo da média verdadeira. Com n elevado, pelo Teorema do Limite Central, a média amostral aproxima-se de uma distribuição normal e a cobertura converge para 0,95.

Conclui-se que nem todos os intervalos de confiança são fiáveis: o nível de 95% só é garantido com dados normais ou com amostras suficientemente grandes, e o tamanho necessário aumenta com a assimetria da distribuição. Para distribuições muito assimétricas, 50 observações não são suficientes.

Exercício 12

Método

Executou-se 10 vezes o simulador M/M/1 do Anexo A do guia, com $\lambda = 1$ e $\mu = 1,25$ ($\rho = \lambda/\mu = 0,8$), terminando cada execução quando são determinados os atrasos em fila de 1000 clientes. As execuções são independentes entre si, uma vez que a semente é definida uma única vez, antes das 10 execuções, e cada uma utiliza uma sequência diferente de números aleatórios. Os resultados foram comparados com o valor teórico, dado por (6), que para $\lambda = 1$ e $\mu = 1,25$ é $W_Q = 3,2$.

$$W_Q = \frac{\lambda/\mu}{\mu - \lambda} \quad (6)$$

Resultados e discussão

Execução	W_Q simulado	Erro relativo
1	3,127	-2,3%
2	3,580	+11,9%
3	3,271	+2,2%
4	3,664	+14,5%
5	2,567	-19,8%
6	3,052	-4,6%

Execução	W_Q simulado	Erro relativo
7	2,417	-24,5%
8	2,590	-19,1%
9	2,484	-22,4%
10	2,756	-13,9%
Média	2,951	-7,8%
Desvio padrão	0,455	

Tabela 6: Atraso médio em fila estimado em 10 execuções independentes do simulador M/M/1 ($\rho = 0,8$; valor teórico $W_Q = 3,2$).

As estimativas variam entre 2,417 e 3,664, o que corresponde a erros relativos entre -24,5% e +14,5% face ao valor teórico. A diferença entre o valor máximo e o mínimo (1,25) representa cerca de 39% do valor teórico. Consoante a execução utilizada, a conclusão seria muito diferente: a execução 3 obtém um valor muito próximo do teórico, enquanto a execução 7 subestima o atraso em cerca de 25%.

Esta variabilidade deve-se à carga elevada do sistema. Com $\rho = 0,8$, os atrasos de clientes consecutivos estão fortemente correlacionados, uma vez que um período de congestionamento afeta muitos clientes seguidos. Assim, 1000 atrasos contêm muito menos informação do que 1000 observações independentes.

Verifica-se ainda que 7 das 10 execuções ficam abaixo do valor teórico, o que é consistente com o efeito das condições iniciais: cada execução começa com o sistema vazio, pelo que os primeiros clientes têm atrasos reduzidos, o que tende a subestimar W_Q em execuções curtas.

Conclui-se que uma única execução não é suficiente para tirar conclusões. É necessário realizar várias execuções independentes e apresentar a média acompanhada de um intervalo de confiança, tendo também em conta o período transitório inicial.

Exercicio 13

Foram realizadas 25 simulações independentes de um sistema M/M/1, com $\lambda = 3$ e $\mu = 4$, considerando comprimentos de execução de 20 e 2000 atrasos e condições iniciais de 0 e 10 clientes no sistema. Para cada configuração calculou-se a média do atraso em fila e o respetivo intervalo de confiança de 95%.

O valor teórico do atraso médio em regime estacionário é

$$W_Q = \frac{\lambda}{\mu(\mu - \lambda)} = 0,75.$$

Comprimento	Clientes iniciais	Atraso médio	IC 95%
20	0	0.3929	[0.2650, 0.5207]
2000	0	0.7802	[0.72, 0.8405]
20	10	2.2662	[1.9507, 2.5818]
2000	10	0.7388	[0.6801, 0.7974]

Tabela 7 - Atraso médio em fila e intervalo de confiança de 95% para as quatro configurações.

Nos ensaios de menor duração, as condições iniciais apresentam um efeito significativo: iniciar o sistema vazio tende a produzir inicialmente atrasos inferiores aos de regime estacionário, enquanto a presença de 10 clientes conduz a atrasos iniciais superiores. Este comportamento corresponde ao regime transitório, cuja evolução depende do estado inicial do sistema.

Para 2000 atrasos, o efeito das condições iniciais torna-se muito menos relevante, uma vez que as observações do período transitório representam apenas uma pequena parte da execução. Assim, as estimativas obtidas para ambas as condições iniciais aproximam-se entre si e do valor teórico de 0.75, mostrando que execuções mais longas reduzem o impacto das condições iniciais.

Exercício 14

Foi aplicado o método de replicação/eliminação à estimação do atraso médio em fila de um sistema M/M/1. Em cada réplica são eliminadas as observações iniciais, de forma a reduzir o efeito do regime transitório, sendo adicionadas novas réplicas até ser satisfeita a precisão definida pelo erro relativo.

Analisou-se o número de réplicas necessárias em função do erro relativo, do número de atrasos utilizados em cada réplica e da utilização do sistema, $\rho = \lambda/\mu < 1$, mantendo os restantes parâmetros constantes em cada experiência.




Figura 7 - Número de réplicas em função do erro relativo, do número de atrasos e de ρ .

Os resultados mostram que uma redução do erro relativo exige, em geral, um maior número de réplicas, uma vez que é imposta uma maior precisão à estimativa. Por outro lado, o aumento do número de atrasos considerados em cada réplica tende a estabilizar a média estimada e, consequentemente, a reduzir o número de réplicas necessárias.

Para interpretar o efeito da utilização do sistema, considerou-se também a variância teórica do atraso em fila,

$$\sigma_{W_q}^2 = \frac{\rho(2-\rho)}{\mu^2(1-\rho)^2}.$$




Figura 8 - Variância teórica do atraso em fila em função de ρ .

Observa-se que a variância aumenta rapidamente quando ρ se aproxima de 1, evidenciando uma maior variabilidade dos atrasos em sistemas próximos da saturação. Esta evolução permite contextualizar as diferenças observadas no número de réplicas requerido para diferentes valores de utilização.